

Sprawozdanie z Projektu

Klasyfikacja Danych (Heart Disease & Wine Quality)

1. Wstęp


Celem projektu było stworzenie modeli uczenia maszynowego do klasyfikacji dwóch różnych zestawów danych:

1. **Heart Disease:** Klasyfikacja binarna (0 - zdrowy, 1 - chory).
2. **Wine Quality:** Klasyfikacja wieloklasowa (ocena jakości wina w skali 1-10).


Wykorzystaliśmy algorytmy **Drzewa Decyzyjnego (Decision Tree)** oraz **Maszyny Wektorów Nośnych (SVM)**,

2. Wizualizacja Danych

Wygenerowaliśmy wykres słupkowy (countplot), aby sprawdzić zbalansowanie zbiorów.



- **Obserwacja dla Heart Disease:** Zbiór jest stosunkowo zbalansowany (podobna liczba przypadków zdrowych i chorych).



- **Obserwacja dla Wine Quality:** Zbiór jest silnie niezbalansowany. Najwięcej win posiada oceny 5 i 6, podczas gdy oceny skrajne są rzadkie, co utrudnia klasyfikację.

3. Metryki Jakości Klasyfikacji

Do oceny modeli wykorzystaliśmy następujące metryki:

- **Accuracy (Dokładność):** Ogólny procent poprawnych trafień.
- **Precision (Precyzja):** Zdolność modelu do unikania "falszywych alarmów".
- **Recall (Czułość):** Zdolność modelu do wykrywania wszystkich obiektów danej klasy.
- **F1-Score:** Średnia harmoniczna precyzji i czułości (kluczowa przy niezbalansowanych danych).

1. Wyniki dla klasyfikacji **wina**:

```
===== WYNIKI: Drzewo Decyzyjne (Wine Dataset) =====
Accuracy:      0.6061
Precision:     0.6132
Recall:        0.6061
F1-Score:      0.6088
```

```
===== WYNIKI: SVM RBF (Wine Dataset) =====
Accuracy:      0.5612
Precision:     0.5536
Recall:        0.5612
F1-Score:      0.5271
```

2. Wyniki dla klasyfikacji **chorób serca**:

```
===== WYNIKI: Drzewo Decyzyjne (Heart Dataset) =====  
Accuracy:      0.9854  
Precision:     1.0000  
Recall:        0.9709  
F1-Score:      0.9852
```

```
===== WYNIKI: SVM RBF (Heart Dataset) =====  
Accuracy:      0.8878  
Precision:     0.8509  
Recall:        0.9417  
F1-Score:      0.8940
```

4. Klasyfikacja Przykładowych Danych Wejściowych

1. Klasyfikacja dla win na podstawie SVM (RBF):

```
PRÓBKA #1:  
  fixed acid: 7.3      volatile a: 0.19      citric aci: 0.27  
  residual s: 13.9     chlorides: 0.057     free sulfu: 45.0  
  total sulf: 155.0    density: 0.99807    pH: 2.94  
  sulphates: 0.41     alcohol: 8.8  
-> Rzeczywista: 8 | Predykcja: 8 [✅ POPRAWNA]  
  
PRÓBKA #2:  
  fixed acid: 7.0      volatile a: 0.55      citric aci: 0.05  
  residual s: 8.0      chlorides: 0.036     free sulfu: 19.0  
  total sulf: 164.0    density: 0.99269    pH: 3.26  
  sulphates: 0.46     alcohol: 12.2  
-> Rzeczywista: 6 | Predykcja: 6 [✅ POPRAWNA]  
  
PRÓBKA #3:  
  fixed acid: 6.9      volatile a: 0.21      citric aci: 0.33  
  residual s: 1.8      chlorides: 0.034     free sulfu: 48.0  
  total sulf: 136.0    density: 0.9899     pH: 3.25  
  sulphates: 0.41     alcohol: 12.6  
-> Rzeczywista: 7 | Predykcja: 7 [✅ POPRAWNA]
```

1. Klasyfikacja dla chorób serca na podstawie SVM (RBF):

PRÓBKA #1:

age: 65.0 sex: 1.0 cp: 3.0
trestbps: 138.0 chol: 282.0 fbs: 1.0
restecg: 0.0 thalach: 174.0 exang: 0.0
oldpeak: 1.4 slope: 1.0 ca: 1.0
thal: 2.0

-> Rzeczywista: 0 | Predykcja: 1 [ BŁĘDNA]

PRÓBKA #2:

age: 49.0 sex: 1.0 cp: 1.0
trestbps: 130.0 chol: 266.0 fbs: 0.0
restecg: 1.0 thalach: 171.0 exang: 0.0
oldpeak: 0.6 slope: 2.0 ca: 0.0
thal: 2.0

-> Rzeczywista: 1 | Predykcja: 1 [ POPRAWNA]


PRÓBKA #3:

age: 57.0 sex: 0.0 cp: 0.0
trestbps: 128.0 chol: 303.0 fbs: 0.0
restecg: 0.0 thalach: 159.0 exang: 0.0
oldpeak: 0.0 slope: 2.0 ca: 1.0
thal: 2.0

-> Rzeczywista: 1 | Predykcja: 1 [ POPRAWNA]

5. Analiza Funkcji Jądra (Kernel) w SVM

Przeprowadziliśmy eksperyment testując cztery rodzaje jąder z różnymi parametrami. Otrzymane wyniki przedstawiliśmy na wykresie:



Podsumowanie wpływu jąder na wyniki klasyfikacji:

1. Jądro Liniowe (Linear):

- a. **Wyniki:** Bardzo dobre dla zbioru *Heart Disease*, słabsze dla *Wine Quality*.
- b. **Wniosek:** Sprawdza się, gdy granica decyzyjna jest prosta. Jest szybkie w trenowaniu. Parametr C kontroluje margines błędu.

2. Jądro Wielomianowe (Poly):

- a. **Wyniki:** Dobre, ale kosztowne obliczeniowo.
- b. **Wniosek:** Pozwala modelować zakrzywione granice. Zwiększanie stopnia (degree) powyżej 3 często prowadzi do drastycznego spadku wyników na zbiorze testowym z powodu przeuczenia (overfitting).

3. Jądro RBF (Radial Basis Function):

- a. **Wyniki:** Najbardziej stabilne i uniwersalne
- b. **Wpływ parametru Gamma:**
 - i. **Niska Gamma (0.1):** Model tworzy gładkie granice, dobrze generalizuje.
 - ii. **Wysoka Gamma (1.0 - 10.0):** Model tworzy "wyspy" wokół pojedynczych punktów treningowych. Prowadzi to do **perfekcyjnych wyników na treningu, ale fatalnych na teście** (klasyczny przykład przeuczenia).

4. Jądro Sigmoidalne:

- a. **Wyniki:** Najsłabsze w testowanych przypadkach.
- b. **Wniosek:** Jądro to zachowuje się podobnie do sieci neuronowych (tangens hiperboliczny), ale jest trudne w tuningu i rzadko stosowane jako pierwszy wybór w SVM.