

Sprawozdanie z projektu

1. Uczenie sieci rozpoznawać jakość win:

```
Epoch 36/50
98/98 ██████████ 0s 4ms/step - accuracy: 0.5855 - loss: 0.9585 - val_accuracy: 0.5816 - val_loss: 1.0389
Epoch 37/50
98/98 ██████████ 0s 3ms/step - accuracy: 0.5919 - loss: 0.9613 - val_accuracy: 0.5727 - val_loss: 1.0356
Epoch 38/50
98/98 ██████████ 0s 3ms/step - accuracy: 0.5960 - loss: 0.9580 - val_accuracy: 0.5740 - val_loss: 1.0373
Epoch 39/50
98/98 ██████████ 0s 2ms/step - accuracy: 0.5922 - loss: 0.9597 - val_accuracy: 0.5804 - val_loss: 1.0342
Epoch 40/50
98/98 ██████████ 0s 2ms/step - accuracy: 0.5925 - loss: 0.9530 - val_accuracy: 0.5676 - val_loss: 1.0366
Epoch 41/50
98/98 ██████████ 0s 2ms/step - accuracy: 0.5967 - loss: 0.9572 - val_accuracy: 0.5880 - val_loss: 1.0347
Epoch 42/50
98/98 ██████████ 0s 2ms/step - accuracy: 0.5890 - loss: 0.9549 - val_accuracy: 0.5765 - val_loss: 1.0355
Epoch 43/50
98/98 ██████████ 0s 2ms/step - accuracy: 0.5817 - loss: 0.9598 - val_accuracy: 0.5778 - val_loss: 1.0315
Epoch 44/50
98/98 ██████████ 0s 2ms/step - accuracy: 0.5941 - loss: 0.9549 - val_accuracy: 0.5867 - val_loss: 1.0278
Epoch 45/50
98/98 ██████████ 0s 2ms/step - accuracy: 0.6002 - loss: 0.9530 - val_accuracy: 0.5765 - val_loss: 1.0353
Epoch 46/50
98/98 ██████████ 0s 2ms/step - accuracy: 0.6015 - loss: 0.9480 - val_accuracy: 0.5702 - val_loss: 1.0317
Epoch 47/50
98/98 ██████████ 0s 2ms/step - accuracy: 0.5999 - loss: 0.9435 - val_accuracy: 0.5804 - val_loss: 1.0310
Epoch 48/50
98/98 ██████████ 0s 2ms/step - accuracy: 0.5919 - loss: 0.9426 - val_accuracy: 0.5791 - val_loss: 1.0381
Epoch 49/50
98/98 ██████████ 0s 2ms/step - accuracy: 0.5948 - loss: 0.9408 - val_accuracy: 0.5740 - val_loss: 1.0311
Epoch 50/50
98/98 ██████████ 0s 2ms/step - accuracy: 0.5922 - loss: 0.9562 - val_accuracy: 0.5855 - val_loss: 1.0293
31/31 ██████████ 0s 2ms/step - accuracy: 0.5592 - loss: 1.0375
Dokładność: 55.92%

Process finished with exit code 0
```


2. Porównanie skuteczności sieci neuronowej i drzewa decyzyjnego/svm:

Oto porównanie skuteczności trzech metod klasyfikacji na zbiorze danych o winie.

Dokładność:

- Drzewo Decyzyjne: 61.02%
- SVM: 56.12%
- Sieć Neuronowa: 58.47%

W tym konkretnym przypadku **najlepsze okazało się proste Drzewo Decyzyjne**. Sieci neuronowe zyskują przewagę dopiero przy bardzo dużej ilości danych lub przy danych surowych (zdjęcia, dźwięk), gdzie same muszą wykrywać cechy.



```
31/31 ————— 0s 2ms/step
Dokładność Drzewa Decyzyjnego: 61.02%
Dokładność SVM: 56.12%
Dokładność Sieci Neuronowej: 58.06%
```

3. Porównanie wyników między rozmiarami sieci:

Porównaliśmy dwa modele:

- Mały Model: Tylko jedna ukryta warstwa (16 neuronów). Bardzo prosta sieć.
- Duży Model: Trzy ukryte warstwy (256, 128, 64 neuronów).

Wyniki:

- Mały Model: Dokładność - 54.49%
- Duży Model: Dokładność - 57,96%

Trenowanie małego modelu...



Trenowanie dużego modelu...

Wyniki na zbiorze testowym:

Mały model - Dokładność: 54.49%, Strata: 1.0762


Duży model - Dokładność: 57.96%, Strata: 1.0271

Process finished with exit code 0



4. Rozpoznawanie zwierząt (CIFAR10):

```
Epoch 1/10
1563/1563 ————— 16s 10ms/step - accuracy: 0.4652 - loss: 1.4832 - val_accuracy: 0.5607 - val_loss: 1.2333
Epoch 2/10
1563/1563 ————— 15s 9ms/step - accuracy: 0.5929 - loss: 1.1501 - val_accuracy: 0.6190 - val_loss: 1.0658
Epoch 3/10
1563/1563 ————— 14s 9ms/step - accuracy: 0.6490 - loss: 1.0090 - val_accuracy: 0.6523 - val_loss: 0.9978
Epoch 4/10
1563/1563 ————— 15s 10ms/step - accuracy: 0.6768 - loss: 0.9282 - val_accuracy: 0.6570 - val_loss: 0.9947
Epoch 5/10
1563/1563 ————— 15s 10ms/step - accuracy: 0.7015 - loss: 0.8601 - val_accuracy: 0.6820 - val_loss: 0.9286
Epoch 6/10
1563/1563 ————— 18s 12ms/step - accuracy: 0.7231 - loss: 0.7995 - val_accuracy: 0.6896 - val_loss: 0.8979
Epoch 7/10
1563/1563 ————— 22s 14ms/step - accuracy: 0.7383 - loss: 0.7586 - val_accuracy: 0.6890 - val_loss: 0.9218
Epoch 8/10
1563/1563 ————— 21s 13ms/step - accuracy: 0.7528 - loss: 0.7161 - val_accuracy: 0.6972 - val_loss: 0.8985
Epoch 9/10
1563/1563 ————— 14s 9ms/step - accuracy: 0.7644 - loss: 0.6799 - val_accuracy: 0.6990 - val_loss: 0.8996
Epoch 10/10
1563/1563 ————— 13s 9ms/step - accuracy: 0.7746 - loss: 0.6485 - val_accuracy: 0.7072 - val_loss: 0.8862
Obliczanie macierzy pomyłek...
313/313 ————— 1s 3ms/step
313/313 - 1s - 5ms/step - accuracy: 0.7072 - loss: 0.8862
Osiągnięta dokładność: 70.72%
```




W przypadku CIFAR-10, macierz pomyłek zazwyczaj pokazuje ciekawe zależności:

- Kot vs Pies: Te dwie klasy często się mylą (sieć widzi "czworonoga z futrem").
- Samochód vs Ciężarówka: Częste pomyłki ze względu na podobną budowę.
- Samolot vs Ptāk: Czasami mylone, jeśli samolot jest na niebieskim tle, a ptāk też lata.
- Samolot vs Statek: Obie klasy często mają dużo koloru niebieskiego (niebo / woda) w tle, co jest mylące.

5. Rozpoznawanie ubrań:

```
Epoch 1/10
1875/1875 ————— 14s 7ms/step - accuracy: 0.8317 - loss: 0.4640 - val_accuracy: 0.8465 - val_loss: 0.3924
Epoch 2/10
1875/1875 ————— 12s 6ms/step - accuracy: 0.8877 - loss: 0.3110 - val_accuracy: 0.8800 - val_loss: 0.3257
Epoch 3/10
1875/1875 ————— 12s 6ms/step - accuracy: 0.9020 - loss: 0.2663 - val_accuracy: 0.8949 - val_loss: 0.2884
Epoch 4/10
1875/1875 ————— 13s 7ms/step - accuracy: 0.9135 - loss: 0.2355 - val_accuracy: 0.9034 - val_loss: 0.2591
Epoch 5/10
1875/1875 ————— 14s 7ms/step - accuracy: 0.9232 - loss: 0.2092 - val_accuracy: 0.9044 - val_loss: 0.2631
Epoch 6/10
1875/1875 ————— 13s 7ms/step - accuracy: 0.9301 - loss: 0.1880 - val_accuracy: 0.9045 - val_loss: 0.2670
Epoch 7/10
1875/1875 ————— 21s 7ms/step - accuracy: 0.9373 - loss: 0.1691 - val_accuracy: 0.9090 - val_loss: 0.2604
Epoch 8/10
1875/1875 ————— 13s 7ms/step - accuracy: 0.9418 - loss: 0.1551 - val_accuracy: 0.9035 - val_loss: 0.2734
Epoch 9/10
1875/1875 ————— 13s 7ms/step - accuracy: 0.9478 - loss: 0.1382 - val_accuracy: 0.9067 - val_loss: 0.2810
Epoch 10/10
1875/1875 ————— 13s 7ms/step - accuracy: 0.9525 - loss: 0.1270 - val_accuracy: 0.9107 - val_loss: 0.2784
Tworzenie macierzy pomyłek...
313/313 ————— 1s 3ms/step
313/313 - 1s - 3ms/step - accuracy: 0.9107 - loss: 0.2784
Osiągnięta dokładność: 91.07%
```



Można zauważyć, że największy problem stanowiło rozpoznawanie koszuli, często jest mylona z koszulką, płaszczem lub np. swetrem.

6. Rozpoznawanie niemieckich znaków drogowych:

[illegible]

Z rozróżnianiem znaków drogowych ze zdjęć sieć poradziło sobie wyjątkowo dobrze. Najwięcej pomyłek pojawiło przy **zakazie wyprzedzania**, który często był mylony z **końcem zakazu wyprzedzania**.